# Ejercicios Sab24

### January 31, 2018

```
In [1]: import numpy as np
                                  y = [0, 1, 2, 3, 4]
In [2]: mi_arreglo = [0, 1, 2, 3, 4]
In [3]: type(mi_arreglo)
Out[3]: list
In [4]: mi_arreglo_numpy = np.array(mi_arreglo)
In [5]: type(mi_arreglo_numpy)
Out[5]: numpy.ndarray
In [6]: help(np.array)
Help on built-in function array in module numpy.core.multiarray:
array(...)
    array(object, dtype=None, copy=True, order=None, subok=False, ndmin=0)
    Create an array.
    Parameters
    _____
    object : array_like
        An array, any object exposing the array interface, an
        object whose __array__ method returns an array, or any
        (nested) sequence.
    dtype : data-type, optional
        The desired data-type for the array. If not given, then
        the type will be determined as the minimum type required
        to hold the objects in the sequence. This argument can only
        be used to 'upcast' the array. For downcasting, use the
        .astype(t) method.
```

```
copy : bool, optional
    If true (default), then the object is copied. Otherwise, a copy
    will only be made if __array__ returns a copy, if obj is a
    nested sequence, or if a copy is needed to satisfy any of the other
    requirements ('dtype', 'order', etc.).
order : {'C', 'F', 'A'}, optional
    Specify the order of the array. If order is 'C', then the array
   will be in C-contiguous order (last-index varies the fastest).
    If order is 'F', then the returned array will be in
   Fortran-contiguous order (first-index varies the fastest).
    If order is 'A' (default), then the returned array may be
    in any order (either C-, Fortran-contiguous, or even discontiguous),
    unless a copy is required, in which case it will be C-contiguous.
subok : bool, optional
    If True, then sub-classes will be passed-through, otherwise
    the returned array will be forced to be a base-class array (default).
ndmin : int, optional
    Specifies the minimum number of dimensions that the resulting
    array should have. Ones will be pre-pended to the shape as
   needed to meet this requirement.
Returns
_____
out : ndarray
    An array object satisfying the specified requirements.
See Also
_____
empty, empty_like, zeros, zeros_like, ones, ones_like, fill
Examples
_____
>>> np.array([1, 2, 3])
array([1, 2, 3])
Upcasting:
>>> np.array([1, 2, 3.0])
array([ 1., 2., 3.])
More than one dimension:
>>> np.array([[1, 2], [3, 4]])
array([[1, 2],
       [3, 4]])
Minimum dimensions 2:
```

```
>>> np.array([1, 2, 3], ndmin=2)
    array([[1, 2, 3]])
    Type provided:
    >>> np.array([1, 2, 3], dtype=complex)
    array([ 1.+0.j, 2.+0.j, 3.+0.j])
    Data-type consisting of more than one element:
    >>> x = np.array([(1,2),(3,4)],dtype=[('a','<i4'),('b','<i4')])
    >>> x['a']
    array([1, 3])
    Creating an array from sub-classes:
    >>> np.array(np.mat('1 2; 3 4'))
    array([[1, 2],
            [3, 4]])
    >>> np.array(np.mat('1 2; 3 4'), subok=True)
    matrix([[1, 2],
             [3, 4]])
In [7]: mi_arreglo_numpy * mi_arreglo_numpy
Out[7]: array([0, 1, 4, 9, 16])
In [9]: np.ndim(mi_arreglo_numpy)
Out[9]: 1
In [10]: mi_arreglo_numpy.size
Out[10]: 5
0.0.1 Matrices (Arreglos de dos dimensiones)
                                     x = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}
In [11]: mi_matriz_numpy = np.array([[1,2,3],
                                       [4,5,6],
                                       [7,8,9]])
```

In [15]: print(mi\_matriz\_numpy.ndim, mi\_matriz\_numpy.size)

```
Selección escalar
```

```
In [13]: print(mi_matriz_numpy)
[[1 2 3]
 [4 5 6]
[7 8 9]]
In [16]: mi_matriz_numpy[1,2]
Out[16]: 6
In [21]: mi_matriz_numpy[1:2]
Out[21]: array([[4, 5, 6]])
  • a[comienzo:fin] # elementos desde el índice del comienzo hasta el índice fin-1
  • a[comienzo:] # del número en comienzo hasta el fin
  • a[:fin] # desde el principio hasta fin-1
   • a[:] # todo el arreglo
   • a[comienzo:fin:paso] # elementos desde el índice del comienzo hasta el índice fin-1, por paso
In [22]: mi_matriz_numpy
Out[22]: array([[1, 2, 3],
                 [4, 5, 6],
                 [7, 8, 9]])
In [23]: mi_matriz_numpy * 2
Out[23]: array([[ 2, 4, 6],
                 [8, 10, 12],
                 [14, 16, 18]])
In [24]: mi_matriz_numpy + 100
Out[24]: array([[101, 102, 103],
                 [104, 105, 106],
                 [107, 108, 109]])
In [27]: mi_matriz_numpy + mi_matriz_numpy
Out[27]: array([[ 2, 4, 6],
                 [8, 10, 12],
```

[14, 16, 18]])

In [35]: mi\_matriz\_numpy

```
Out[35]: array([[1, 2, 3],
                [4, 5, 6],
                [7, 8, 9]])
In [37]: mi_matriz_numpy.flatten()
Out[37]: array([1, 2, 3, 4, 5, 6, 7, 8, 9])
In [68]: %timeit mi_matriz_numpy.flatten().ndim
The slowest run took 103.69 times longer than the fastest. This could mean that an intermediate
1000000 loops, best of 3: 982 ns per loop
In [71]: %timeit np.ndim(mi_matriz_numpy.flatten())
The slowest run took 19.89 times longer than the fastest. This could mean that an intermediate
100000 loops, best of 3: 1.25 ts per loop
In [72]: mi_matriz_numpy.mean()
Out[72]: 5.0
In [73]: mi_matriz_numpy.std()
Out[73]: 2.5819888974716112
In [74]: import pandas as pd
In [82]: mi_serie = pd.Series([1, 2, 3, 4, 5],
                             index = ['a', 'b', 'c','d', 'e'])
        mi_serie
Out[82]: a
              1
              2
              3
              4
              5
         dtype: int64
In [83]: mi_serie[['a', 'd']]
Out[83]: a
              1
              4
         dtype: int64
In [87]: mi_serie[mi_serie>2]
```

```
Out[87]: c
              3
              4
         d
              5
         dtype: int64
In [106]: mi_df = pd.DataFrame({
              'municipio': ['mty', 'spgg', 'sta_c', 'garcia'],
              'temp_celcius_jueves': [35, 36, 37, 38],
              'temp_celcius_viernes': [36, 37, 39, 38]
          })
          mi_df['temp_celcius_jueves']
Out[106]: 0
               35
          1
               36
          2
               37
          Name: temp_celcius_jueves, dtype: int64
In [124]: mi_df[mi_df['temp_celcius_jueves'] < 38]['temp_celcius_jueves']</pre>
Out[124]: 0
               35
               36
          1
               37
          Name: temp_celcius_jueves, dtype: int64
In [123]: mi_df[[mi_df['temp_celcius_jueves'] < 38] and</pre>
               mi_df['temp_celcius_viernes'] < 38]</pre>
Out [123]:
          municipio temp_celcius_jueves temp_celcius_viernes
          0
                  mty
                                         35
                                                                36
          1
                                                                37
                                         36
                 spgg
In [149]: miarreglo2 = pd.DataFrame({
              'municipio': ['mpio8', 'municipio 53'],
              'temp_celcius_jueves': [35, 45],
              'temp_celcius_viernes': [36, 42]
          })
          miarreglo2
Out [149]:
                municipio temp_celcius_jueves temp_celcius_viernes
                    mpio8
          0
                                              35
                                                                     36
          1 municipio 53
                                              45
                                                                     42
In [150]: mi_df = mi_df.append(miarreglo2, ignore_index=True)
          mi_df
```

Out[150]:	municipio	temp_celcius_jueves	temp_celcius_viernes
0	mty	35	36
1	spgg	36	37
2	sta_c	37	39
3	garcia	38	38
4	laredo	35	36
5	nvo_laredo	35	36
6	china	45	42
7	mpio4	35	36
8	municipio 5	45	42
9	mpio8	35	36
10	municipio 53	45	42

### 1 http://bit.ly/2sCuFc5

In [152]: url\_dataset = 'https://gist.githubusercontent.com/israelzuniga/de79faf13d5fe48ea4f65

#### 1.0.1 **Datos**

Los datos son características cualitativas o cuantitativas pertenecientes a un objeto, o un conjunto de objetos

#### 1.0.2 Datos en bruto

"Raw data is a term for data collected on source which has not been subjected to processing or any other manipulation."

- Los datos en bruto llegan directamente de la fuente y no tienen la estructura necesaria para realizar análisis con ellos eficientemente.
- Requieren pre-procesamiento para ser utilizados.
- Por lo general suelen verse de la siguiente manera:

Video, audio, páginas web, también son fuentes de datos

#### 1.0.3 Datos ordenados (Tidy data)

#### Notebook Tidy\_data

• Las variables deben de ser entendibles para el humano

**Codebook!** Documento para poder entender la información de la tabla.

- Descripción de las características con sus unidades
- Instrucciones sobre las transformaciones que aplicamos a nuestros datos en bruto para trabajarlos

#### ESTO ES MUY IMPORTANTE

Existen historias de terror:

http://www.cc.com/video-clips/dcyvro/the-colbert-report-austerity-s-spreadsheet-error

#### 1.1 Dataset para hoy - train.csv

#### 1.1.1 Predecir la supervivencia en el Titanic

https://www.kaggle.com/c/titanic/data

El hundimiento del Titanic es uno de los naufragios más infames de la historia. El 15 de abril de 1912, durante su viaje inaugural, el Titanic se hundió después de chocar con un iceberg, matando de 1,502 a 2,224 pasajeros.

Una de las razones por las cuales se perdieron tantas vidas fue que no había suficientes botes salvavidas. Aunque hubo algún elemento de suerte involucrada en sobrevivir al hundimiento, algunos grupos de personas tenían más probabilidades de sobrevivir que otros, como las mujeres, los niños y personas de la clase alta.

Param hoy usaremos el dataset train.csv y completarás el análisis de qué tipo de personas eran propensos a sobrevivir . En un futuro, te pedimos aplicar las herramientas de aprendizaje automático para predecir que los pasajeros sobrevivieron a la tragedia.

#### 1.1.2 Matplotlib

Las visualizaciones son una de las herramientas más poderosas a su disposición para explorar los datos y comunicar tus ideas. La biblioteca pandas incluye capacidades básicas para graficar con el paquete matplotlib.

```
In [226]: titanic = pd.read_csv(url_dataset)
In [227]: titanic.Age = titanic.Age.fillna(29)
In [228]: titanic.describe()
Out [228]:
                 PassengerId
                                 Survived
                                                Pclass
                                                                Age
                                                                           SibSp
                  891.000000
                               891.000000
                                           891.000000
                                                        891.000000
                                                                     891.000000
          count
                  446.000000
                                 0.383838
                                              2.308642
                                                          29.560236
                                                                       0.523008
          mean
                   257.353842
                                 0.486592
                                              0.836071
                                                          13.005010
                                                                        1.102743
          std
                     1.000000
                                 0.000000
                                              1.000000
                                                           0.420000
                                                                       0.000000
          min
          25%
                   223.500000
                                 0.000000
                                              2.000000
                                                          22.000000
                                                                       0.000000
                                              3.000000
                                                          29.000000
          50%
                  446.000000
                                 0.000000
                                                                       0.000000
          75%
                   668.500000
                                 1.000000
                                              3.000000
                                                          35.000000
                                                                        1.000000
          max
                  891.000000
                                 1.000000
                                              3.000000
                                                          80.000000
                                                                        8.000000
                                     Fare
                       Parch
                 891.000000
                              891.000000
          count
                   0.381594
                               32.204208
          mean
          std
                    0.806057
                               49.693429
          min
                    0.000000
                                0.000000
          25%
                    0.000000
                                7.910400
          50%
                    0.000000
                               14.454200
                    0.000000
          75%
                               31.000000
          max
                    6.000000
                              512.329200
```

```
Out[160]:
                PassengerId
                              Survived
                                        Pclass
           879
                         880
                                      1
                                               1
                                      1
                                               2
           880
                         881
                         882
                                      0
                                               3
           881
                                      0
                                               3
           882
                         883
                                      0
                                               2
           883
                         884
           884
                         885
                                      0
                                               3
           885
                         886
                                      0
                                               3
                                      0
                                               2
           886
                         887
           887
                         888
                                      1
                                               1
                                      0
                                               3
           888
                         889
                                      1
                                               1
           889
                         890
                                               3
                                      0
           890
                         891
                                                                       Sex
                                                                              Age
                                                                                   SibSp
                                                                                           \
           879
                Potter, Mrs. Thomas Jr (Lily Alexenia Wilson)
                                                                    female
                                                                             56.0
                                                                                        0
           880
                 Shelley, Mrs. William (Imanita Parrish Hall)
                                                                    female
                                                                             25.0
                                                                                        0
           881
                                              Markun, Mr. Johann
                                                                             33.0
                                                                                        0
                                                                      male
                                   Dahlberg, Miss. Gerda Ulrika
                                                                    female
                                                                             22.0
                                                                                        0
           882
           883
                                  Banfield, Mr. Frederick James
                                                                      male
                                                                             28.0
                                                                                        0
                                                                      male
           884
                                          Sutehall, Mr. Henry Jr
                                                                             25.0
                                                                                        0
                          Rice, Mrs. William (Margaret Norton)
           885
                                                                    female
                                                                             39.0
                                                                                        0
           886
                                           Montvila, Rev. Juozas
                                                                      male
                                                                             27.0
                                                                                        0
                                   Graham, Miss. Margaret Edith
                                                                    female
                                                                                        0
           887
                                                                             19.0
                      Johnston, Miss. Catherine Helen "Carrie"
           888
                                                                    female
                                                                              NaN
                                                                                        1
                                           Behr, Mr. Karl Howell
                                                                                        0
           889
                                                                      male
                                                                             26.0
           890
                                             Dooley, Mr. Patrick
                                                                             32.0
                                                                                        0
                                                                      male
                Parch
                                   Ticket
                                               Fare Cabin Embarked
           879
                                    11767
                                            83.1583
                                                       C50
                                                                   С
                     1
                                                                   S
           880
                                   230433
                                            26.0000
                                                       NaN
                     1
                                             7.8958
           881
                     0
                                   349257
                                                       NaN
                                                                   S
                                                                   S
           882
                     0
                                     7552
                                            10.5167
                                                       NaN
                        C.A./SOTON 34068
                                            10.5000
                                                                   S
           883
                     0
                                                       NaN
                         SOTON/OQ 392076
                                             7.0500
                                                                   S
           884
                     0
                                                       NaN
           885
                     5
                                   382652
                                            29.1250
                                                       NaN
                                                                   Q
                                            13.0000
                                                                   S
           886
                     0
                                   211536
                                                       NaN
           887
                     0
                                   112053
                                            30.0000
                                                       B42
                                                                   S
                     2
                              W./C. 6607
                                            23.4500
                                                                   S
           888
                                                       NaN
                                                                   C
           889
                     0
                                   111369
                                            30.0000
                                                      C148
           890
                     0
                                   370376
                                             7.7500
                                                                   Q
                                                       NaN
In [162]: titanic.describe()
Out [162]:
                  PassengerId
                                                                              SibSp
                                   Survived
                                                  Pclass
                                                                   Age
           count
                   891.000000
                                 891.000000
                                              891.000000
                                                           714.000000
                                                                        891.000000
                   446.000000
                                   0.383838
                                                2.308642
                                                            29.699118
                                                                           0.523008
           mean
```

0.836071

14.526497

1.102743

0.486592

257.353842

std

```
min
                    1.000000
                                 0.000000
                                             1.000000
                                                         0.420000
                                                                      0.000000
          25%
                  223.500000
                                 0.000000
                                             2.000000
                                                                      0.00000
                                                         20.125000
          50%
                  446.000000
                                 0.000000
                                             3.000000
                                                         28.000000
                                                                      0.000000
          75%
                  668.500000
                                 1.000000
                                             3.000000
                                                         38.000000
                                                                      1.000000
                                 1.000000
                                             3.000000
          max
                  891.000000
                                                         80.000000
                                                                      8.000000
                      Parch
                                    Fare
          count
                 891.000000 891.000000
                   0.381594
                               32.204208
          mean
          std
                   0.806057
                               49.693429
          min
                   0.000000
                                0.000000
          25%
                   0.000000
                                7.910400
          50%
                   0.000000
                               14.454200
          75%
                   0.000000
                               31.000000
          max
                   6.000000 512.329200
In [163]: titanic.shape
Out[163]: (891, 12)
In [164]: len(titanic)
Out[164]: 891
In [165]: len(titanic.keys())
Out[165]: 12
In [168]: edad = titanic['Age']
In [171]: sum(edad.isnull())
Out[171]: 177
In [175]: np.mean(edad)
Out[175]: 29.69911764705882
In [176]: edad = titanic['Age'].fillna(29)
In [177]: sum(edad.isnull())
Out[177]: 0
In [178]: np.mean([1,2,3])
Out[178]: 2.0
In [183]: titanic.Pclass.unique()
Out[183]: array([3, 1, 2])
```

```
In [186]: titanic['Pclass'].unique()
Out[186]: array([3, 1, 2])
In [190]: titanic[['Pclass', 'Age']].head()
Out[190]:
             Pclass
                      Age
          0
                  3 22.0
          1
                  1 38.0
          2
                  3 26.0
          3
                  1 35.0
          4
                     35.0
```

Podemos borrar columnas usando los comando del, pop(), drop() - del modifica nuestro dataframe borrando la Serie seleccionada. - pop() borra la Serie pero la regresa como un output - drop() regresa un dataframe sin la Serie, pero no modifica el dataframe original

```
In [192]: titanic.keys()
Out[192]: Index(['PassengerId', 'Survived', 'Pclass', 'Name', 'Sex', 'Age', 'SibSp',
                 'Parch', 'Ticket', 'Fare', 'Cabin', 'Embarked'],
                dtype='object')
In [225]: titanic.head(1)
Out [225]:
             PassengerId Survived Pclass
                                                                Name SibSp Fare \
                       1
                                         3 Braund, Mr. Owen Harris
                                                                          1 7.25
            Embarked
In [205]: # - pop() borra la Serie pero la regresa como un output
          cabin = titanic.pop('Cabin')
In [224]: # drop() regresa un dataframe sin la Serie, pero no modifica el
          # dataframe original
          titanic = titanic.drop('Sex', axis=1)
In [206]:
Out[206]: 0
                         NaN
          1
                         C85
          2
                         NaN
          3
                        C123
          4
                         NaN
          5
                         NaN
          6
                         E46
          7
                         NaN
```


8			NaN
9			NaN
10			G6
11		(	C103
12			NaN
13			NaN
14			NaN
15			NaN
16			NaN
17			NaN
18			${\tt NaN}$
19			${\tt NaN}$
20			${\tt NaN}$
21			D56
22			${\tt NaN}$
23			A6
24			NaN
25			NaN
26			NaN
27	C23	C25	C27
28			NaN
29			NaN
861		• • •	NaN
862			D17
863			NaN
864			NaN
865			NaN
866			NaN
867			A24
868			NaN
869			NaN
870			NaN
871			D35
872	B51	B53	B55
873	DOI	DOO	NaN
874			NaN
875			NaN
876			NaN
877			NaN
878			NaN
879			C50
880			NaN
881			NaN
882			NaN
883			NaN
884			NaN N-N
885			NaN

```
886 NaN
887 B42
888 NaN
889 C148
890 NaN
```


Name: Cabin, dtype: object

In [246]: titanic.boxplot(column='Fare', by='Pclass', return\_type='axes')

Out[246]: OrderedDict([('Fare', <matplotlib.axes.\_subplots.AxesSubplot at 0x113162dd8>)])



Out[247]: <matplotlib.axes.\_subplots.AxesSubplot at 0x112fa0668>




mi\_tabla\_cruzada

Out[270]: Survived All **Pclass** All 

Out[261]: Survived 0 1 All Pclass
1 0.370370 0.629630 1.0
2 0.527174 0.472826 1.0
3 0.757637 0.242363 1.0
All 0.616162 0.383838 1.0

In [262]: mi\_tabla\_cruzada.plot(kind='bar')

Out[262]: <matplotlib.axes.\_subplots.AxesSubplot at 0x1136cb278>



## In [256]:

Out[256]: Int64Index([0, 1], dtype='int64', name='Survived')